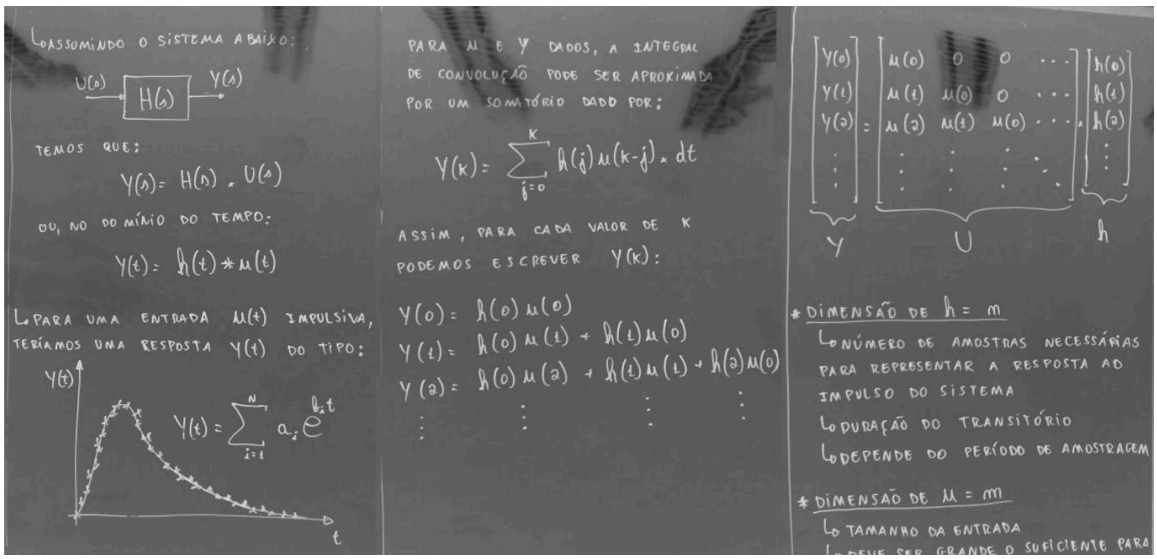
MODELAGEM E SIMULAÇÃO

Uma abordagem experimental para obtenção de modelos determinísticos e simulação numérica



TÓPICO 2 : MODELAGEM DE SISTEMAS ESTÁTICOS (O CASO DA RETA)

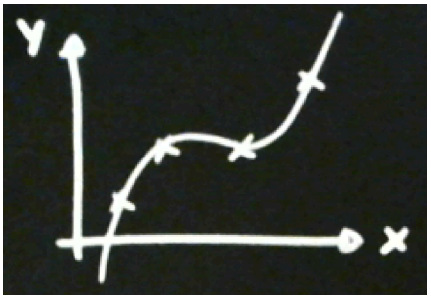
Prof. Lucas Molina
lmolina@academico.ufs.br

Modelos de sistemas estáticos:

- No domínio dos sistemas estáticos, um modelo pode ser definido matematicamente através de uma função.
- As equações utilizadas como modelos podem ser lineares ou não lineares.
- Na abordagem experimental, ou caixa preta, o **problema básico** consiste em escolher adequadamente uma entrada para um sistema para que, com base na observação da resposta do sistema a essa entrada, seja possível propor uma função (equação, modelo) que representa o sistema real e estimar os parâmetros dessa equação a partir dos dados coletados.
- Esse procedimento pode ser dividido em **três partes**:
  - **Escolha dos dados de entrada**
  - **Proposição de equação candidata para o modelo**
  - **Estimação dos parâmetros do modelo**

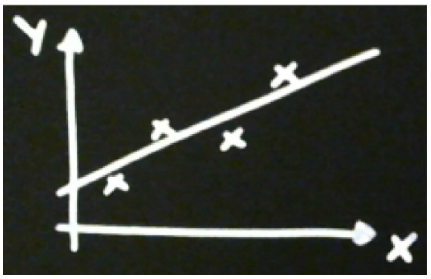
- Antes de falar de cada uma dessas etapas é interessante fazer uma discussão sobre os tipos de abordagem que se aplicam ao problema em questão.
  - **Interpolação**
  - **Regressão**
- A **interpolação** é utilizada quando os dados são extremamente confiáveis. Nesse tipo de abordagem o modelo deve passar exatamente em cima de todas as amostras de saída observadas.
  - Splines

Ilustração de uma **solução por interpolação**:



- A **regressão** considera que os dados não são medidas perfeitas. Dados reais de sistemas de engenharia são predominantemente medidas adquiridas através de equipamentos e que, portanto, apresentam ruídos associados ao processo de medição. Dessa forma, modelos de regressão não têm por objetivo representar exatamente todas as amostras do sistema mas sim a **tendência das amostras**.

Ilustração de uma **solução por regressão**:



- Por serem de maior aplicabilidade em modelagem de sistemas reais na nossa área,os modelos de regressão serão nosso foco de estudo nesta disciplina.

Etapas para a obtenção do modelo:

Escolha dos dados de entrada:

- Na escolha dos dados de entrada devemos nos preocupar com duas características principais:
  - **Janela de observação:** os valores utilizados como entrada de um sistema devem estar espalhados em um intervalo que compreenda a região de interesse (ponto de operação) em que o sistema deve operar.
  - **Frequência de observação:** dentro da janela de observação, a densidade de amostras tomadas para os valores de entrada deve ser capaz de representar todas as componentes de frequência que possam ser de interesse para o sistema a ser modelado.
    - Taxa de Nyquist ideal = 2 vezes a maior frequência.
    - Na prática, a frequência de observação deve ser 10 vezes maior do que a maior frequência de interesse do sistema.

Proposição de uma equação:

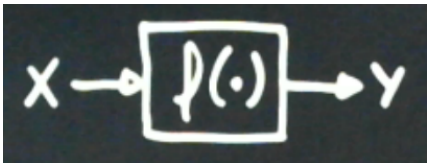
- Escolhida a entrada, ela deve ser aplicada no sistema que se quer modelar e a saída do sistema deve ser observada.
- Com base na observação do projetista, uma equação para o modelo do sistema deve ser proposta.
- É importante ressaltar que diferentes escolhas de dados de entrada podem levar à proposição de diferentes funções para representar um mesmo sistema.
- Existem formas mais automatizadas de definir uma equação para o modelo de um sistema mas não serão alvo de estudo neste curso.

Estimação dos parâmetros:

- Obtidos experimentalmente os dados de saída associados a cada uma das amostras de entrada selecionadas e tendo escolhido uma equação para representar o modelo, precisamos agora determinar os parâmetros do modelo.
- A técnica de estimação de parâmetros a ser utilizada está intimamente associada ao tipo de função (equação) proposta como modelo.
- Nesse primeiro momento, utilizaremos algumas restrições para a escolha dessas funções:
  - Relação estática de entrada e saída
  - Função lineares ou não lineares mas com **relação linear entre os parâmetros**
  - Sistemas podem ter mais de uma entrada e mais de uma saída, mas para fins de ilustração utilizaremos sistemas com apenas uma entrada e uma saída por simplicidade de ilustração
- Consideraremos como estudo de caso o problema de estimar parâmetros de uma reta.

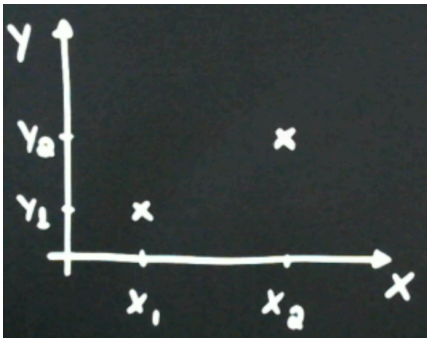
Estudo de caso: Reta

Considere o sistema ilustrado abaixo em que a equação matemática proposta como modelo para o sistema é a equação de uma reta definida por:



$$y = f(x) = \theta_1 x + \theta_2$$

- Em que o vetor coluna $\theta = [\theta_1, \theta_2]^T$ é chamado de **vetor de parâmetros** do modelo.
- Partindo da premissa de que são necessários apenas dois pontos para definir uma reta, escolheremos dois pontos quaisquer $(x_1 \ e \ x_2)$ como entradas de teste, aplicaremos estas entradas no sistema em questão e observaremos a resposta do sistema $(y_1 \ e \ y_2)$.
- O resultado é ilustrado graficamente na figura abaixo:



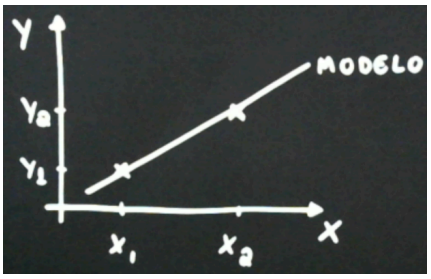
- Para determinar os valores para os parâmetros da função, precisamos resolver o seguinte sistema de equações:

$$y_1 = \theta_1 x_1 + \theta_2$$
$$y_2 = \theta_1 x_2 + \theta_2$$

- No qual os parâmetros da função são as variáveis a determinar e os valores de **x** e **y** são conhecidos.
- A solução para esse sistema pode ser obtida matricialmente por:

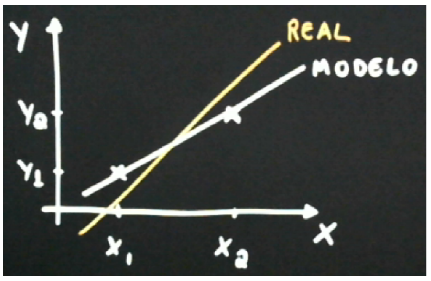
$$A = \begin{pmatrix} x_1 & 1 \\ x_2 & 1 \end{pmatrix} \cdot \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \end{pmatrix}$$
$$\theta = A^{-1} y$$

- A inversa da matriz **A** sempre existirá para amostras de entrada não coincidentes.
- Calculados os parâmetros da função, podemos escrever a equação da reta e plotá-la sobre as amostras:

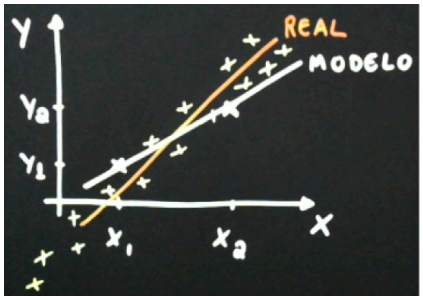


Esse modelo é adequado?

- E se eu disser que esses dados de saída **y** foram coletados utilizando um elemento sensor real e, portanto, está sujeito à interferência de um ruído aditivo na medição?
- Nessas condições, duas amostras podem não mais ser o suficiente para determinar (adequadamente) uma reta (que representa um sistema a ser modelado).



- Como ilustrado acima, vamos supor que essa nova reta incluída no desenho representa o sistema real de fato (claro que em situações reais essa é uma informação desconhecida).
- Obviamente que com nossas duas amostras apenas, o modelo obtido é o melhor candidato possível.
- Outras duas amostras quaisquer poderiam gerar um modelo mais próximo do sistema real, mas isso não seria uma solução de fato pois estaríamos dependendo da sorte ao determinar aleatoriamente duas amostras. Além disso, como o sistema real não é conhecido, não teríamos como saber qual solução seria a melhor.
- Mas e se utilizássemos mais amostras? Será que a redundância nos permitiria propor um modelo melhor para o sistema, considerando que os dados estão corrompidos com ruído?



- Na ilustração acima, o nosso sistema mental de geração de modelos (se é que esse termo existe) nos indicaria uma reta próxima ao sistema real como candidata a modelo do sistema, ou não?
- Beleza! Mentalmente tá fácil. Mas dá pra fazer isso também utilizando um sistema de equações?
- Vamos supor que foram coletadas **k** amostras (pares de entrada e saída) e que essas amostras foram organizadas em dois vetores:
  - **Vetor de entrada:** $x = [x_1, x_2, ..., x_k]^T$
  - **Vetor de saída:** $y = [y_1, y_2, ..., y_k]^T$
- Utilizando a notação matricial, podemos escrever o sistema de equação abaixo:

$$\begin{pmatrix} x_1 & 1 \\ x_2 & 1 \\ x_3 & 1 \\ \dots & \dots \end{pmatrix} \cdot \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ y_3 \\ \dots \end{pmatrix}$$

- Nesse sistema a nossa matriz **A** não é mais uma matriz quadrada.
- Isso implica que o sistema linear **não tem solução** (exceto no caso em que todos os pontos (x,y) amostrados são colineares).
- Isso é meio óbvio pois não existe uma única reta que passe por todas as amostras quando elas não são colineares.
- Se o sistema não tem solução, como achar uma boa aproximação para o modelo?
- Mentalmente nós fizemos isso para o exemplo em que tínhamos muitas amostras. A ideia que utilizamos de forma intuitiva foi criar um modelo que **aproxima** da melhor forma possível uma reta ao conjunto de pontos amostrados.
- Pra fazer isso matematicamente, precisamos de um critério que consiga medir essa **aproximação**, um critério de erro entre o modelo e os dados observados.
- Diferentes medidas de erro podem ser utilizadas mas a que se mostra mais eficiente é o **somatório dos erros ao quadrado** de todas as amostras.
- O erro é mensurado entre o valor de saída observado (y) e o valor de saída estimado pelo modelo (y_m).
- Dessa forma, podemos garantir que todos os erros contribuem individualmente para a escolha do modelo, sem que os sinais de cada um dos erros represente um problema para a nossa solução.
- Pronto! Já temos um sistema de equações que não tem solução e uma métrica que vamos utilizar para encontrar uma solução aproximada.

- E agora?

A ideia é que o erro definido por:

$$S = \sum_{i=1}^{k} (e_i)^2$$

em que $e = y - y_m$, seja **minimizado**.

- Para minimizar essa equação, utilizaremos o conceito de mínimo de uma função que acontece em posições onde a derivada é zero.
- Como a equação de **S** é uma função quadrática, ela não tem máximos e só tem um mínimo, deixando tudo ainda mais fácil!
- Pra saber quem é o mínimo, basta derivar **S** em relação às variáveis independentes (parâmetros da função) e igualar as equações resultantes a zero.
- Os valores de θ_i que resolverem o sistema resultante são os valores que minimizam **S**, logo, nossa solução para a melhor aproximação da equação da reta.
- Escrevendo o sistema de equações com índice i , para i = 1, 2, 3, ... , k, temos:

$$S = \sum_{i=1}^{k} (e_i)^2$$

$$S = \sum_{i=1}^{k} \left(y_i - (y_m)_i\right)^2$$

$$S = \sum_{i=1}^{k} (y_i - (\theta_1 x_i + \theta_2))^2$$

$$S = \sum_{i=1}^{k} (y_i - \theta_1 x_i - \theta_2)^2$$

Derivando S em relação aos parâmetros, temos:

$$\frac{dS}{d\theta_1} = 2\sum_{i=1}^{k}(y_i - \theta_1 x_i - \theta_2)(-x_i)$$

$$\frac{dS}{d\theta_2} = -2\sum_{i=1}^{k}(y_i - \theta_1 x_i - \theta_2)$$

- Organizando essas duas equações no formato de um sistema matricial de equações e omitindo os intervalos de contagem, temos:

$$\begin{pmatrix} \sum(x_i)^2 & \sum(x_i) \\ \sum(x_i) & k \end{pmatrix} \cdot \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix} = \begin{pmatrix} \sum(x_i y_i) \\ \sum(y_i) \end{pmatrix}$$

- Chamando a primeira matriz de B e o último vetor de v, podemos escrever uma solução para o vetor de parâmetros θ utilizando novamente a inversão matricial, uma vez que B é uma matriz quadrada. Assim:

$$\theta = B^{-1}v$$

- E a respeito da invertibilidade de **B**? Ela sempre será invertível (inversível)? Vamos deixar essa discussão para depois da formulação do nosso caso geral, que vai valer para qualquer função (com relação linear entre os parâmetros) e não apenas para a reta.
- Ainda sobre o método apresentado, pelas suas características, seu resultado minimiza o somatório dos erros ao quadrado. Por esse motivo ele é denominado de **Método dos Mínimos Quadrados** ou **MMQ**.

Exercício

Gere um conjunto de **k** pares de entrada e saída a partir da equação y = 3x − 4, em que **k** deve ser igual a 10. Então, pegue os valores de saída **y** e os corrompa com um ruído aditivo gaussiano de média nula e desvio padrão igual a 1.

Esses valores corrompidos serão a nossa saída medida (simulando a interferência de um ruído de medição)

a) Com base nos **k** valores obtidos de **x** e **y** e utilizando como modelo a equação da reta já apresentada, determine através do **MMQ** uma estimativa para os parâmetros θ_1 *e* θ_2.

b) Depois de obter os parâmetros plot em um mesmo gráfico:
- Os dados corrompidos por ruído (utilizando um símbolo qualquer)
- A reta ideal (que representa o sistema real, que na prática é desconhecida)
- A reta do modelo obtida a partir do MMQ

Faça testes para diferentes valores de k **e avalie os resultados.**