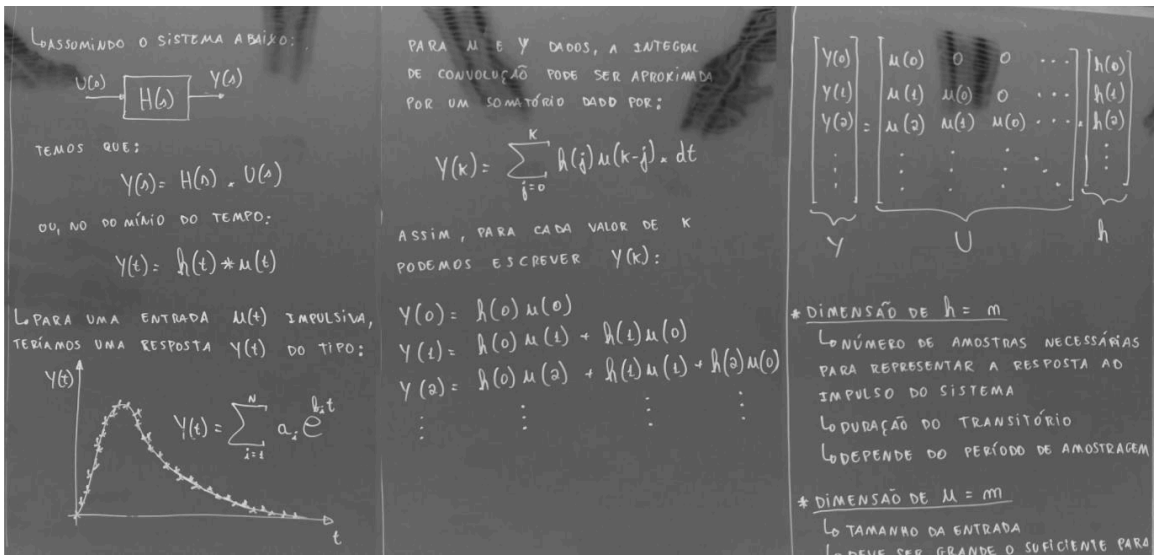
MODELAGEM E SIMULAÇÃO

Uma abordagem experimental para obtenção de modelos determinísticos e simulação numérica

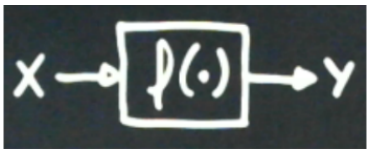


TÓPICO 3 : MODELAGEM DE SISTEMAS ESTÁTICOS (O CASO GERAL)

Prof. Lucas Molina
lmolina@academico.ufs.br

- A ideia desenvolvida para a reta no tópico anterior permite estimar os parâmetros para esse tipo de equação dado um conjunto de dados observados e corrompidos por ruído.
- No entanto, para utilizar a mesma ideia com equações diferentes, todo o processo deve ser refeito envolvendo inclusive derivadas parciais em relação a todos os parâmetros θ_i.
- Para simplificar essa metodologia e permitir a utilização dela com um conjunto mais amplo de funções, utilizaremos uma representação matricial para o MMQ que chamaremos de solução geral.
- Essa solução será desenvolvida para um sistema com uma entrada e uma saída (SISO) mas a metodologia não se restringe a sistemas desse tipo podendo ser aplicada em sistemas com múltiplas entradas e/ou múltiplas saídas (MISO ou MIMO).

Considere um sistema qualquer do tipo:



Em que a função f(x) é uma função estática e com relação linear entre os parâmetros, ou seja, ela sempre pode ser representada por:

$$f(x) = \theta_1 f_1(x) + \theta_2 f_2(x) + \theta_3 f_3(x) + ... + \theta_N f_N(x)$$

- $f_i(x)$ = funções de base
- $x = [x_1, x_2, x_3, ..., x_k]^T$ = *vetor de amostras de entrada com k elementos*
- $y = [y_1, y_2, y_3, ..., y_k]^T$ = *vetor de saídas com k elementos*
- $\theta = [\theta_1, \theta_2, ..., \theta_N]^T$ = *vetor de parâmetros com N elementos*
- Assim, para cada uma das k amostras coletadas do sistema podemos escrever uma equação usando a expressão do modelo.
- Organizando essas equações no formato matricial temos o seguinte sistema de equações:

$$\begin{pmatrix} y_{m1} \\ y_{m2} \\ \vdots \\ y_{mk} \end{pmatrix} = \begin{pmatrix} f_1(x_1) & ... & f_N(x_1) \\ f_1(x_2) & ... & f_N(x_2) \\ \vdots & \ddots & \vdots \\ f_1(x_k) & ... & f_N(x_k) \end{pmatrix} \cdot \begin{pmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_k \end{pmatrix}$$

Ou ainda:

$$y_m = A\theta$$

- Escrevendo agora o critério a minimizar (somatório de erros ao quadrado) utilizando essa notação, temos:

$$S = \sum_{i=1}^{k} e^2$$

Como o erro **e** é dado pela diferença entre o valor observado (y) e o valor estimado pelo modelo (y_m), temos que o vetor de erros de dimensão k pode ser definido por:

$$e = y - y_m = y - A\theta$$

Então, usando o produto interno do vetor coluna e temos que:

$$S = \sum_{i=1}^{k} e^2 = e^T e$$

$$S = (y - A\theta)^T (y - A\theta) = (y^T - \theta^T A^T)(y - A\theta)$$

$$S = y^T y - y^T A\theta - \theta^T A^T y + \theta^T A^T A\theta$$

Fazendo uso das seguintes propriedades de derivação vetorial nas quais **v** e **w** são vetores e **B** é uma matriz quadrada:

$$\frac{d(w^T v)}{dv} = w$$

$$\frac{d(v^T w)}{dv} = w$$

$$\frac{d(v^T w)}{dv} = (B + B^T)v$$

Podemos derivar S em relação ao vetor de parâmetros θ para minimizar S:

$$\frac{\partial S}{\partial \theta} = \frac{d(-y^T A\theta)}{d\theta} + \frac{d(-\theta^T A^T y)}{d\theta} + \frac{d(\theta^T A^T A\theta)}{d\theta} = 0$$

$$\frac{\partial S}{\partial \theta} = -(y^T A)^T - A^T y + \left(A^T A + (A^T A)^T\right)\theta = 0$$

$$-A^T y - A^T y + 2A^T A\theta = 0$$

$$-2A^T y + 2A^T A\theta = 0$$

$$A^T A\theta = A^T y$$

$$\theta = (A^T A)^{-1} A^T y$$

- Se o sistema de equações original y = Aθ tivesse solução ela seria dada por:

$$\theta = A^{-1} y$$

- No entanto, com k > N esse sistema nunca terá solução e A nunca será quadrada.
- A solução aproximada proposta pelo MMQ é definida por:

$$\theta = (A^T A)^{-1} A^T y$$

- Comparando essas duas últimas equações podemos observar que a matriz $(A^T A)^{-1} A^T$ é uma aproximação para a inversa da matriz A.
- Por esse motivo, a matriz $(A^T A)^{-1} A^T$ é chamada de **pseudo inversa à esquerda de A** e ela é a solução do problema de minimização do somatório dos erros ao quadrado.

No caso em questão, quando a pseudoinversa existe?

- *Quando a matriz $A^T A$ tiver inversa.*

Quando a matriz $\left(A^T A\right)^{-1}$ existe?

- *Quando $A^T A$ for de posto completo.*

Quando a matriz $A^T A$ é de posto completo?

- *Quando todas as colunas de A forem linearmente independentes.*

Quem são as colunas de A?

- *Vetores de amostras que representam as funções de base.*

Humm... então as funções de base devem ser linearmente independentes?

- *Na janela de observação em que os dados foram coletados sim.*

Então vou refazer a pergunta...

No caso em questão, **quando a pseudo inversa existe?**

- *Quando as funções de base escolhidas na proposição da equação do modelo forem linearmente independentes para o conjunto de dados observados.*

E se elas não forem tão independentes assim para uma dada janela de observação?

- Quanto mais dependentes linearmente forem as funções de base, mais próximo da singularidade será a matriz $A^T A$ e, por conseguinte, mais distante do resultado esperado será a sua solução (ou seja, vai dá errado).

Pra refletir!

:)