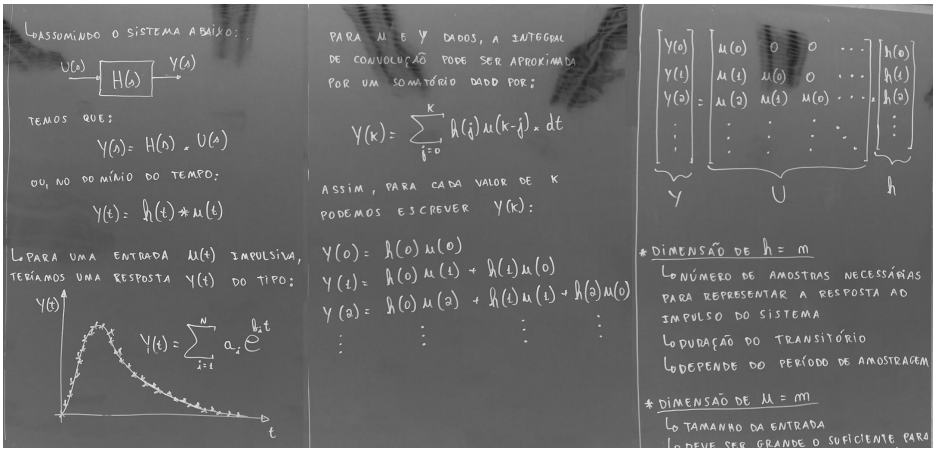
Notas de Aula de
MODELAGEM E SIMULAÇÃO



uma abordagem experimental para obtenção de modelos determinísticos e simulação numérica

Prof. Lucas Molina
lmolina@academico.ufs.br

TÓPICO 4 : Método de Gauss Newton (GN)

- A ideia desenvolvida no tópico anterior permite estimar os parâmetros para para modelos quaisquer, desde que a função escolhida para representar o sistema a ser modelado seja uma função com relação linear entre os parâmetros.
- Mas e se o modelo puder ser melhor representado por funções com relações não lineares entre os parâmetros?
    - Ex.: $y = \theta_1 e^{\theta_2 x}$

- Nesse caso, o MMQ não é suficiente para encontrar um bom ajuste para os parâmetros.
- A primeira evolução que veremos para solucionar o problema é o chamado **Método de Gauss Newton**, aqui chamado de **GN**.
- O **GN** pode ser melhor entendido se for organizado em etapas. A primeira delas tem o objetivo de transformar o problema não linear em um problema linear, mas que só é válido em torno de um **ponto de operação**.

Etapa 1: Linearização

- A alternativa nesse caso é a mesma utilizada em diversas técnicas de solução de sistemas não lineares: **linearização**. No nosso caso, as variáveis a determinar no nosso sistema não linear de equações são os parâmetros do modelo.
- As dimensões do problema continuam as mesmas:
    - ***k*** equações (uma para cada amostra coletada do sistema)
    - ***N*** variáveis (uma para cada parâmetro a determinar na equação do modelo).
- Só que dessa vez, como o sistema é um sistema não linear, não é possível representá-lo com matrizes numéricas, ou seja, não dá pra usar a solução do MMQ.
- Que ferramentas utilizaremos para linearizar o sistema?
    - **Série de Taylor**. No caso do nosso sistema com **N** variáveis a determinar (**N** parâmetros), utilizaremos a série de Taylor multivariável, dada por:

$$y = f(x,\theta) = f(\theta) = f(\bar{\theta}) + \sum_{m=1}^{\infty}\left(\frac{1}{m!}\sum_{i=1}^{N}\left(\frac{d\,f(\bar{\theta})}{d\,\theta_i}(\theta_i - \bar{\theta}_i)\right)^m\right)$$

    - na qual:
        - ***f*** depende do valor observado de ***x*** e dos parâmetros θ. Sua representação mais completa é $y = f(x,\theta)$ mas por simplicidade de notação, quando ***x*** não for importante, utilizaremos $y = f(\theta)$.
        - $\left(\frac{d\,f(\bar{\theta})}{d\,\theta_i}\right)^m$ é a *m-ésima* derivada da função ***f*** em relação ao parâmetro θ_i, avaliada no ponto $\bar{\theta}$.

- **Como a Série de Taylor pode linearizar um sistema?**
    - A equação da série de Taylor pode representar fielmente uma função quando todos os seus infinitos termos são utilizados.
    - No entanto, uma aproximação linear de uma função qualquer pode ser obtida em torno de um ponto de operação no espaço de dimensão ***N***. No nosso caso, esse ponto de operação é simplesmente uma amostra do vetor de parâmetros.
    - Esse ponto de operação é aqui definida como:

$$\bar{\theta} = [\bar{\theta}_1, \bar{\theta}_2, \dots, \bar{\theta}_N]^T$$

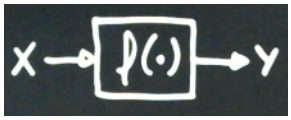
    - Definido o ponto de operação, para encontrar uma aproximação linear para o sistema basta truncar a Série de Taylor nos termos de primeira ordem e desprezando os termos de maior ordem.
    - Fazendo então **m** máximo igual a 1, na equação da série, temos:

$$f(\theta) = f(\bar{\theta}) + \sum_{i=1}^{N} \frac{d f(\bar{\theta})}{d \theta_i} (\theta_i - \bar{\theta}_i)$$

    - Por se tratar de uma aproximação linear em torno de um ponto de operação, essa função só aproxima bem a função original (não linear) nas proximidades desse ponto $\bar{\theta}$.

Etapa 2: Utilização do MMQ no modelo linearizado:

- Agora que temos um sistema linear **local**, ou seja, válido apenas em torno do ponto de operação, podemos escrever uma solução para esse sistema linear utilizando o nosso MMQ.
- A solução será desenvolvida para um sistema com uma entrada e uma saída (SISO) mas a metodologia não se restringe a sistemas desse tipo podendo ser aplicada em sistemas com múltiplas entradas e/ou múltiplas saídas (MISO ou MIMO).
- Considere um sistema qualquer do tipo:



- Em que a função ***f(x,θ)*** é não linear nos parâmetros, mas é **continuamente diferenciável**, para que sempre seja possível aplicar a Série de Taylor para qualquer ponto de operação, sem descontinuidades.
- Agora vamos supor um conjunto de amostras (***x,y***) e parâmetros a determinar (θ), organizados vetorialmente como:
    - $x = [x_1, x_2, x_3, \dots, x_k]^T$ = vetor de amostras de entrada com k elementos
    - $y = [y_1, y_2, y_3, \dots, y_k]^T$ = vetor de amostras de saída com k elementos
    - $\theta = [\theta_1, \theta_2, \dots, \theta_N]^T$ = vetor de parâmetros com N elementos
- Para construir o sistema linear, precisamos da aproximação local e linear dada pela Série de Taylor truncada.
- Por sua vez, para obter a Série de Taylor truncada precisamos definir um ponto de operação $\overline{\theta}$. Quem seria um bom candidato para ser o primeiro ponto de operação?
    - Voltaremos para essa pergunta depois. Por hora, vamos considerar que escolhemos arbitrariamente um valor numérico para cada um dos parâmetros de modo a definir o ponto de operação inicial (**inicialização dos parâmetros**) $\overline{\theta}$.
- Agora que nosso vetor $\overline{\theta}$ é numérico, podemos calcular o modelo linear em torno dele usando a Série de Taylor truncada. Temos então que:

$$y = f(\theta) = f(\overline{\theta}) + \sum_{i=1}^{N} \frac{df(\overline{\theta})}{d\theta_i}(\theta_i - \overline{\theta}_i)$$

$$y = f(\overline{\theta}) + \frac{df(\overline{\theta})}{d\theta_1}(\theta_1 - \overline{\theta}_1) + \frac{df(\overline{\theta})}{d\theta_2}(\theta_2 - \overline{\theta}_2) + \dots + \frac{df(\overline{\theta})}{d\theta_N}(\theta_N - \overline{\theta}_N)$$

- Essa equação ainda não representa um sistema linear. No entanto, se considerarmos que:
    - $\Delta\theta_i = \theta_i - \overline{\theta}_i$
    - $\Delta y = y - f(\overline{\theta})$

- Podemos reescrever a equação da seguinte forma:

$$\Delta y = \frac{d f(\bar{\theta})}{d \theta_1}\Delta\theta_1 + \frac{d f(\bar{\theta})}{d \theta_2}\Delta\theta_2 + \ldots + \frac{d f(\bar{\theta})}{d \theta_N}\Delta\theta_N$$

- Que é uma equação linear, cujas variáveis a determinar são os valores $\Delta\theta_i$.
- Avaliando essa última equação para todos os ***k*** pares de entrada e saída ***(x,y)*** temos o seguinte sistema de equações:

$$\begin{cases} \Delta y_1 = \dfrac{d f(x_1,\bar{\theta})}{d \theta_1}\Delta\theta_1 + \dfrac{d f(x_1,\bar{\theta})}{d \theta_2}\Delta\theta_2 + \cdots + \dfrac{d f(x_1,\bar{\theta})}{d \theta_N}\Delta\theta_N \\ \Delta y_2 = \dfrac{d f(x_2,\bar{\theta})}{d \theta_1}\Delta\theta_1 + \dfrac{d f(x_2,\bar{\theta})}{d \theta_2}\Delta\theta_2 + \cdots + \dfrac{d f(x_2,\bar{\theta})}{d \theta_N}\Delta\theta_N \\ \vdots \\ \Delta y_k = \dfrac{d f(x_k,\bar{\theta})}{d \theta_1}\Delta\theta_1 + \dfrac{d f(x_k,\bar{\theta})}{d \theta_2}\Delta\theta_2 + \cdots + \dfrac{d f(x_k,\bar{\theta})}{d \theta_N}\Delta\theta_N \end{cases}$$

- Organizando esse sistema no formato matricial, temos:

$$\begin{bmatrix} \Delta y_1 \\ \Delta y_2 \\ \vdots \\ \Delta y_k \end{bmatrix} = \begin{bmatrix} \dfrac{d f(x_1,\bar{\theta})}{d \theta_1} & \dfrac{d f(x_1,\bar{\theta})}{d \theta_2} & \cdots & \dfrac{d f(x_1,\bar{\theta})}{d \theta_N} \\ \dfrac{d f(x_2,\bar{\theta})}{d \theta_1} & \dfrac{d f(x_2,\bar{\theta})}{d \theta_2} & & \dfrac{d f(x_2,\bar{\theta})}{d \theta_N} \\ \vdots & & \ddots & \vdots \\ \dfrac{d f(x_k,\bar{\theta})}{d \theta_1} & \dfrac{d f(x_k,\bar{\theta})}{d \theta_2} & \cdots & \dfrac{d f(x_k,\bar{\theta})}{d \theta_N} \end{bmatrix} \begin{bmatrix} \Delta\theta_1 \\ \Delta\theta_2 \\ \vdots \\ \Delta\theta_N \end{bmatrix}$$

Ou ainda:

$$\Delta y = J\,\Delta\theta$$

- Em que **J** é chamada de **matriz Jacobiana do sistema** e tem dimensão **k *x* N**.
- Notem que o sistema ilustrado é um **sistema linear** e, se tivermos **k > N**, podemos aplicar diretamente o MMQ.
- Nesse caso, a solução do problema é dada por:

$$\Delta\theta = (J^T J)^{-1} J^T \Delta y$$

Etapa 3: Atualização do ponto de operação:

- O resultado da etapa anterior nos deu um vetor $\Delta\theta$ de dimensão **N**.
- Uma vez que:

$$\Delta\theta = \theta - \bar{\theta}$$

Podemos interpretar o valor obtido em $\Delta\theta$ como um **passo de atualização** do nosso ponto de operação atual ($\bar{\theta}$) para alcançar a solução desejada (θ), ou seja:

$$\theta = \bar{\theta} + \Delta\theta$$

- Mas, precisamos lembrar que esse valor $\Delta\theta$ foi obtido a partir de uma **aproximação local e linear** da solução real do sistema. Isso tem duas consequências:
    - A primeira é que não podemos esperar que ao somar $\bar{\theta}$ com $\Delta\theta$ teremos a solução do nosso sistema, θ. Como a solução do MMQ é local, o máximo que podemos esperar é que $\Delta\theta$ seja um **passo na direção da solução,** mas que outros passos serão necessários. Ou seja, $\Delta\theta$ deve ser utilizado como uma atualização do ponto de operação.

$$\bar{\theta} = \bar{\theta} + \Delta\theta$$

    - A segunda consequência é que, como a Série de Taylor só funciona nas proximidades do ponto de operação, não é interessante que o valor de $\Delta\theta$ seja grande para evitar se afastar muito da validade da solução.
    - Para manter esse controle, utilizaremos um amortecimento α para reduzir linearmente o tamanho do passo $\Delta\theta$, com α definido entre 0 e 1.

$$\bar{\theta} = \bar{\theta} + \alpha\,\Delta\theta$$

- Quando o amortecimento linear α não é suficiente para controlar o valor de $\Delta\theta$ e garantir assim passos pequenos, podemos usar um amortecimento não linear, como a saturação dos elementos de $\Delta\theta$ ou mesmo do módulo do vetor $\Delta\theta$ inteiro. Pela saturação ser uma operação não linear, é interessante utilizá-la após o amortecimento linear, caso este último não seja suficiente.

Etapa 4: Iteração

- Pelo que foi visto na etapa anterior, a solução do MMQ local nos dará um passo pequeno na direção da solução θ.
- Para alcançar a solução de fato, o método precisará calcular novos passos para continuar "andando" na direção da solução.
- Como o sistema é não linear, o passo $\Delta\theta$ calculado na etapa anterior não vale para outros pontos de operação. Dessa forma, precisaremos de um novo cálculo de $\Delta\theta$ para cada novo ponto de operação calculado, o que indica que a nossa solução é um método recursivo.
- A sequência a seguir é a seguinte:
  - Escolhe um ponto de operação inicial
  - Lineariza o sistema em torno desse ponto de operação
  - Calcula um passo $\Delta\theta$ usando MMQ no sistema linear
  - Utiliza o vetor $\Delta\theta$para atualizar o ponto de operação $\overline{\theta}$
  - Com o ponto de operação atualizado, voltamos para a etapa de linearização e repetimos o algoritmo até que tenhamos alcançado a nossa solução θ.
- A propósito, quando é que saberemos quando alcançamos a solução θ?
  - Bom... alcançar a solução significa que o vetor de parâmetros **minimizou** o somatório dos erros ao quadrado. Quando isso acontecer o vetor $\Delta\theta$ será igual a zero, já que estaremos em um ponto de mínimo.
  - Então para saber quando encontramos uma solução basta observar o módulo do vetor $\Delta\theta$, quando ele for perto o suficiente de zero, significa que podemos parar as iterações. Esse será nosso **critério de parada**.

- Outra coisa... quando alcançamos uma solução $\Delta\theta$ é igual a zero. Mas será que sempre que $\Delta\theta$ for zero significa que encontramos uma solução?
    - A resposta é... não!
    - Como estamos trabalhando com um sistema não linear, não há garantias de que temos um único mínimo no sistema. Podem existir **mínimos globais** (solução desejada) e podem existir **mínimos locais** (ponto de estagnação que não representam solução mas impedem o algoritmo de continuar evoluindo.
- O que fazer se minha solução convergir para um mínimo local?
    - Tenta outra vez! mas não adianta simplesmente rodar o mesmo programa se seu método for completamente determinístico.
    - Considerando que nosso método é **determinístico**, sempre que você iniciar em um mesmo ponto de operação e utilizar os mesmos **parâmetros de convergência** do algoritmo (amortecimento e critério de parada), o seu resultado será o mesmo.
    - Assim, para que em um novo teste você não caia no mesmo mínimo local, precisamos alterar ou parâmetros de convergência ou ponto de operação inicial.
    - Para garantir um **comportamento estocástico** ao método, é comum utilizar uma **inicialização aleatória para o ponto de operação**. Dessa forma, ao executar novamente o seu código ele realizará uma nova tentativa de convergir para a solução desejada. Essa nova tentativa terá probabilidade quase infinita de ser uma execução diferente da anterior.
    - Algumas outras orientações serão dadas sobre formas de inicialização mais à frente.

Exemplo de uma iteração do GN

- O GN foi apresentado de forma literal até aqui. Para facilitar o entendimento, vamos realizar todas as etapas ao menos uma vez com um problema simples e com dados numéricos.
- Consideraremos que temos em mãos os seguintes dados:

- $x = [0, 1, 2]^T$
- $y = [3, 2, 1]^T$
- O que implica que nesse exemplo temos **k = 3.**
- A função escolhida para o modelo é a função $y = \theta_1 e^{\theta_2 x}$. O que implica que o nosso número de parâmetros a determinar é **N = 2**.

- Para a nossa inicialização do ponto de operação usaremos:
  - $\bar{\theta} = [\bar{\theta}_1, \bar{\theta}_2]^T = [1, 2]^T$

- A Série de Taylor truncada da função fica:

$$y = f(\bar{\theta}) + \sum_{i=1}^{2} \frac{df(\bar{\theta})}{d\theta_i}(\theta_i - \bar{\theta}_i)$$

$$y = f(\bar{\theta}) + \frac{df(\bar{\theta})}{d\theta_1}(\theta_1 - \bar{\theta}_1) + \frac{df(\bar{\theta})}{d\theta_2}(\theta_2 - \bar{\theta}_2)$$

$$\Delta y = \frac{df(\bar{\theta})}{d\theta_1}\Delta\theta_1 + \frac{df(\bar{\theta})}{d\theta_2}\Delta\theta_2$$

- Calculando as derivadas em relação aos parâmetros e avaliando-as no ponto de operação, temos:
  - $\frac{df(\bar{\theta})}{d\theta_1} = e^{\bar{\theta}_2 x}$
  - $\frac{df(\bar{\theta})}{d\theta_2} = x\bar{\theta}_1 e^{\bar{\theta}_2 x}$
- Substituindo as derivadas na equação temos o modelo linear em torno do ponto de operação:

$$\left(y - \bar{\theta}_1 e^{\bar{\theta}_2 x}\right) = \left(e^{\bar{\theta}_2 x}\right)\Delta\theta_1 + \left(x\bar{\theta}_1 e^{\bar{\theta}_2 x}\right)\Delta\theta_2$$

- ou ainda, substituindo o valor de $\bar{\theta}_1$ e $\bar{\theta}_2$:

$$\left(y - e^{2x}\right) = \left(e^{2x}\right)\Delta\theta_1 + \left(xe^{2x}\right)\Delta\theta_2$$

- Nesse modelo, as únicas variáveis a determinar são os elementos $\Delta\theta_1$ e $\Delta\theta_2$.
- Avaliando essa equação para cada um dos 3 pontos **(x,y)**, temos:
    - Para (x,y) = (0,3)

$$(3 - 1) = (1)\Delta\theta_1 + (0)\Delta\theta_2$$

    - Para (x,y) = (1,2)

$$\left(2 - e^{2}\right) = \left(e^{2}\right)\Delta\theta_1 + \left(e^{2}\right)\Delta\theta_2$$

    - Para (x,y) = (2,1)

$$\left(1 - e^{4}\right) = \left(e^{4}\right)\Delta\theta_1 + \left(2e^{4}\right)\Delta\theta_2$$

- Escrevendo esse sistema de 3 equações em seu formato matricial, temos:

$$\begin{bmatrix} 2 \\ 2 - e^2 \\ 1 - e^4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ e^2 & e^2 \\ e^4 & 2e^4 \end{bmatrix} \begin{bmatrix} \Delta\theta_1 \\ \Delta\theta_2 \end{bmatrix}$$

$$\begin{bmatrix} 2 \\ -5{,}39 \\ -53{,}6 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 7{,}4 & 7{,}4 \\ 54{,}6 & 109{,}2 \end{bmatrix} \begin{bmatrix} \Delta\theta_1 \\ \Delta\theta_2 \end{bmatrix}$$

- Resolvendo o sistema usando MMQ, encontramos:

$$\Delta\theta = [-0,3 \quad , \quad -0,33]^T$$

- Considerando um amortecimento linear α igual a 0,1, o novo ponto de operação será:

$$\overline{\theta}_{novo} = \overline{\theta} + \alpha\,\Delta\overline{\theta} = [1\,,\,2]^T + [-0,03\,,\quad -0,033]^T$$

$$\overline{\theta}_{novo} = [0,97 \quad , \quad 1,967]^T$$

- Com o novo ponto de operação encontrado, retornamos para a etapa de linearização e calculamos um novo passo de ajuste do ponto de operação até que o módulo de $\Delta\theta$ alcance o critério de parada definido.
- O Exemplo ilustrado acima de uma iteração do GN pode ser realizado utilizando o Octave/Matlab com o seguinte código:

```
x = [0 1 2]';
y = [3 2 1]';
th = [1 2]';
alfa = 0.1;

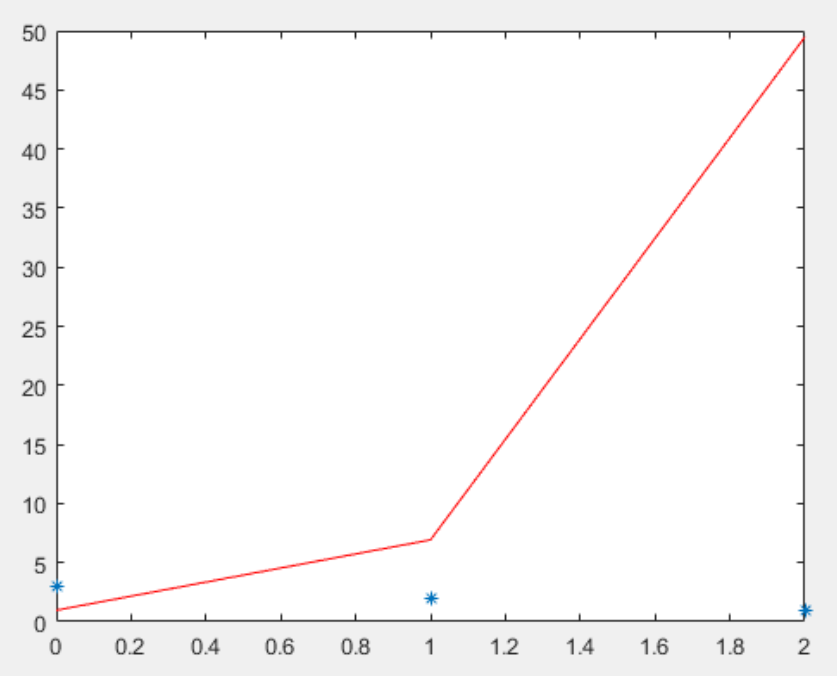
ym = th(1)*exp(th(2)*x);
dy = y - ym;

d1 = exp(th(2)*x);
d2 = th(1)*x.*exp(th(2)*x);
J = [d1 d2];

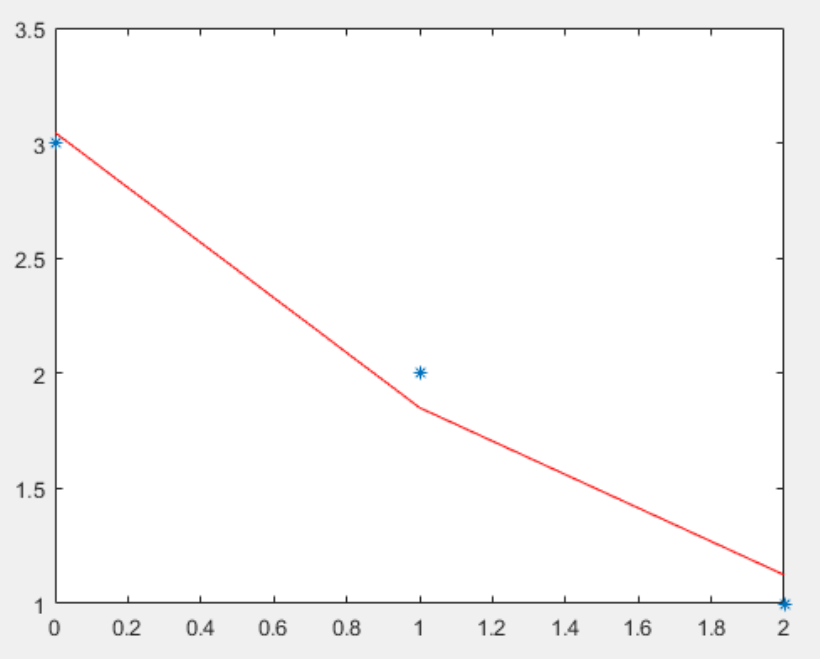
dth = inv(J'*J)*J'*dy;
th = th + alfa*dth;

ym = th(1)*exp(th(2)*x);
```

- Esse é o resultado do modelo (em vermelho) plotado sobre os 3 pontos utilizados (asteriscos azuis) após uma iteração do método.



- Esse é o resultado do modelo (em vermelho) plotado sobre os 3 pontos utilizados (asteriscos azuis) após 100 iterações do método.



- Exercício 1: Complemente o programa de exemplo apresentado para que ele execute iterativamente o método de GN até 100 iterações e verifique se o seu resultado é o mesmo apresentado na figura acima.

- Exercício 2: Agora, pegue o seu código do exercício anterior e ao invés de parar com 100 iterações, faça o seu programa parar quando atingir um critério de parada definido por você. Utilize as explicações dessas notas de aula para escolher seu critério de parada.